Analyse Transcriptomique de la Réponse aux Glucocorticoïdes dans les Cellules Musculaires Lisses des Voies Aériennes et Modélisation Temporelle

ROUQUET Pierre POINT Yvon ABOASHOUR Mahmoud

11 janvier 2026

Résumé

Ce rapport présente une double analyse. Premièrement, nous effectuons une reproduction et un examen critique d'un pipeline d'analyse RNA-Seq visant à identifier les changements transcriptomiques dans des cellules primaires de muscle lisse des voies aériennes (ASM) humaines traitées à la dexaméthasone. Deuxièmement, nous étendrons nos recherches en analysant l'effet du traitement sur l'expression génique à travers le temps à l'aide de Réseaux de Neurones Récurrents (RNN).

Table des matières

1 Introduction **2**

2 Des lectures brutes à la quantification des gènes **2**
2.1 Description du Jeu de Données 2
2.2 Pipeline d'Analyse RNA-Seq 2

3 Analyse d'expression différentielle **3**
3.1 Données d'entrée 3
3.2 Prétraitement et séléction des données 3
3.3 Expression différentielle 5
3.4 Analyse des voies métaboliques 7

4 Séries temporelles / RNN **8**
4.1 Données et format 8
4.2 Objectif 8
4.3 Prétraitement : standardisation 8
4.4 Construction du dataset supervisé 9
4.5 Modèle RNN (GRU) et configuration 9
4.6 Entraînement et early stopping 10
4.7 Évaluation en mode autoregressif 10
4.8 Baselines et comparaison 11

5 Conclusion et Perspectives **12**
5.1 Bilan de l'analyse transcriptomique 12
5.2 Apport de la modélisation temporelle (RNN) 12
5.3 Synthèse et limites 12

1 Introduction

L'asthme est une maladie respiratoire inflammatoire chronique qui touche plus de 300 millions de personnes dans le monde [1]. Un tissu clé impliqué dans la physiopathologie de l'asthme est le muscle lisse des voies aériennes (ASM), qui contribue à l'hyperréactivité et au remodelage des voies aériennes.

Les glucocorticoïdes (GC), tels que la dexaméthasone, constituent le traitement principal de l'asthme en raison de leurs puissants effets anti-inflammatoires. Ils agissent en se liant au récepteur des glucocorticoïdes (GR), qui se transpose dans le noyau pour moduler la transcription des gènes. Cependant, les mécanismes spécifiques par lesquels les GC suppriment l'inflammation dans l'ASM en particulier restent partiellement incompris.

Dans l'étude de référence, le gène *CRISPLD2* a été identifié comme un gène répondant aux glucocorticoïdes qui module la fonction des cytokines. L'objectif de ce rapport est de traiter les données brutes de séquençage RNA (paired-end) pour retrouver ces connaissances biologiques et de modéliser ensuite l'évolution temporelle de l'expression génique à l'aide de réseaux de neurones.

2 Des lectures brutes à la quantification des gènes

2.1 Description du Jeu de Données

Le jeu de données principal consiste en un séquençage RNA-Seq de cellules primaires de muscle lisse des voies aériennes (ASM) provenant de quatre donneurs blancs de sexe masculin. Les cellules ont été traitées avec 1 μM de dexaméthasone (DEX), de l'albutérol (ALB), un bronchodilatateur à action rapide, les deux (ALB+DEX), ou un véhicule témoin (Untreated) pendant 18 heures.

— **Séquençage :** Illumina HiSeq 2000, lectures **paired-end** de 75 pb.
— **Profondeur :** Moyenne de 58,9 millions de lectures brutes par échantillon.

2.2 Pipeline d'Analyse RNA-Seq

Pour évaluer l'expression différentielle des gènes, nous avons mis en œuvre à partir d'un échantillon réduit le pipeline suivant :

1. **Contrôle Qualité :** Nous avons d'abord vérifié la qualité des données brutes. Le contrôle qualité initial via FastQC et MultiQC a révélé une profondeur moyenne de 8 350 reads par échantillon pour une longueur de 63 bases. L'interprétation statistique montre un taux de duplication acceptable (env 30%) et peu de séquences surreprésentées (<4%). Cependant, une chute de qualité ainsi qu'un pic de "N" ont été observés sur les 12 premières bases. Globalement, peu de séquences disposent d'un Phred Score inférieur à 20. (voir Figure 1).

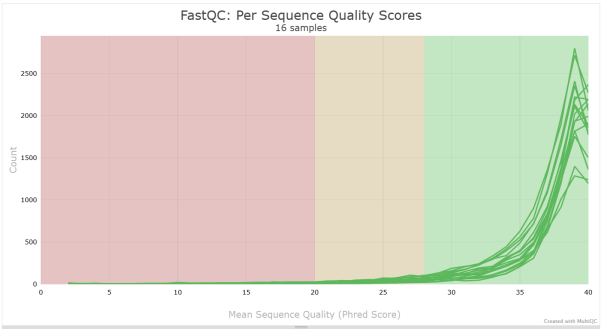

FIGURE 1 – Qualité des séquences brutes (Phred Score)

2. **Nettoyage (Trimming) :** En conséquence aux problèmes soulevés par l'analyse des données brutes, un nettoyage via Cutadapt a été effectué avec les paramètres suivants : Retrait des 12 premières bases (R1 et R2) / Seuil de qualité (cutoff) fixé à 20 / Longueur minimale des reads de 20 bases / Utilisation d'adaptateurs personnalisés pour le mode paired-end. L'analyse FastQC post-nettoyage a confirmé la disparition des anomalies techniques (voir Figure 2).

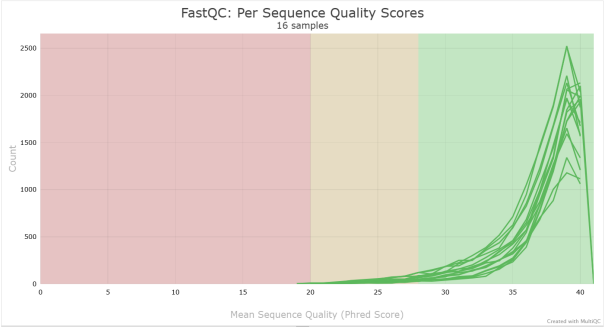

FIGURE 2 – Qualité des séquences brutes après trimming(Phred Score)

3. **Alignement :** Le mapping a été réalisé avec HISAT2 en utilisant le génome de référence hg19, conformément à la méthodologie de Himes. Bien que l'information sur le protocole de librairie soit inconnue, le mode "unstranded" a été sélectionné. L'étape de featureCounts a permis d'obtenir un excellent taux d'alignement de 90%.

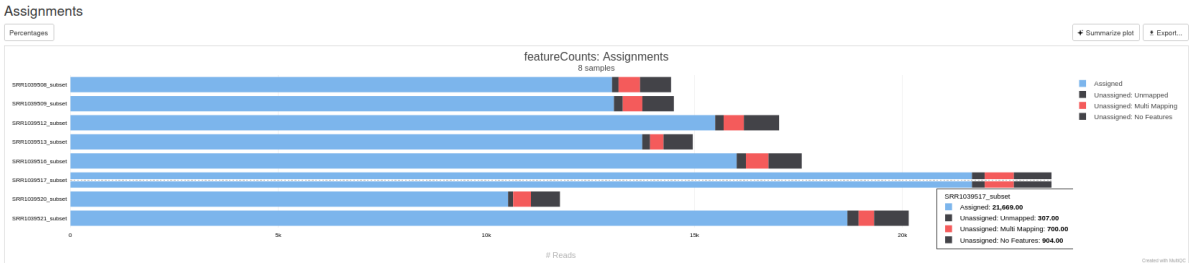

FIGURE 3 – Qualité de l'alignement

4. **Quantification :** Les niveaux d'expression génique ont été quantifiés via featureCounts. Nous obtenons donc nos nombres de lectures par gène.

3 Analyse d'expression différentielle

3.1 Données d'entrée

Pour l'analyse biologique, nous avons utilisé les données complètes (GSE52778) et le fichier de métadonnées associé. L'outil annotateMyIDs a permis de faire correspondre les identifiants Entrez ID aux noms de gènes officiels.

3.2 Prétraitement et séléction des données

Une première analyse de l'expression différentielle (Dex vs Témoin) a été tentée (CPM = 0,5 dans au moins 4 échantillons) avec l'outil Limma-voom.

Résultats : 57,74% des gènes ont été filtrés. On retire les gènes très faiblement exprimés car nous ne pouvons pas en extraire de conclusions statistiquement fiables.

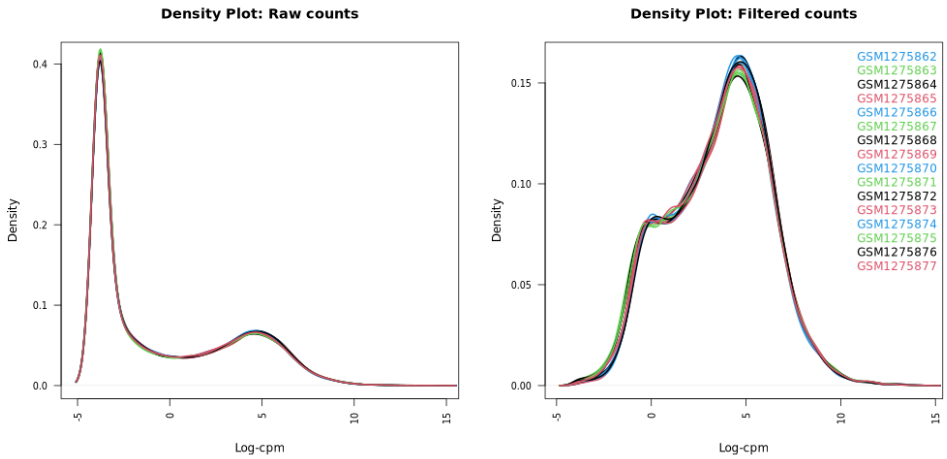

FIGURE 4 – Comparaison des log-CPM avant et après filtration

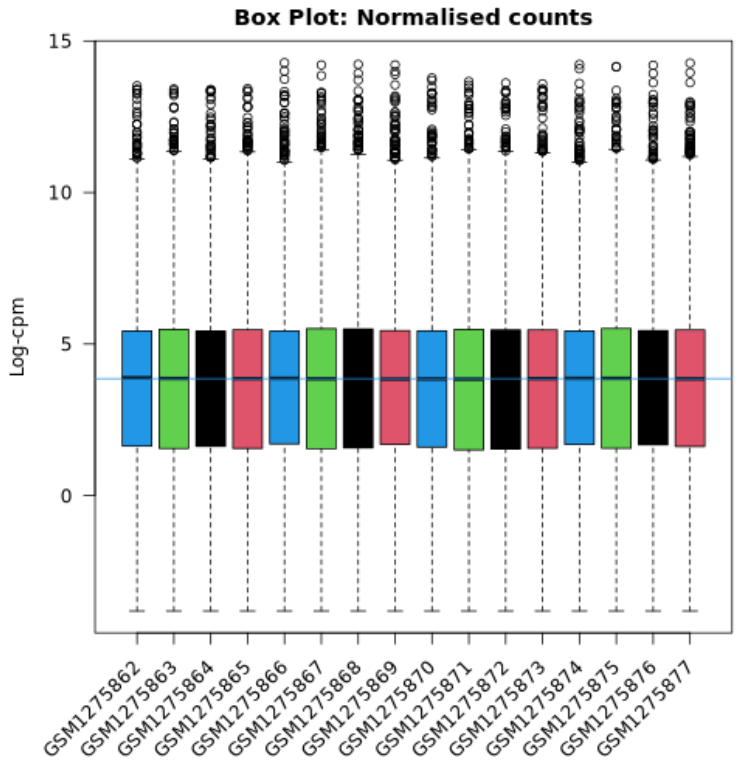

FIGURE 5 – Box plot : Log-CPM après normalisation

La normalisation (TMM) semble correcte d'après les boxplots, elle nous permet de retirer un biais lié à la concentration globale en ARN de chaque échantillon.

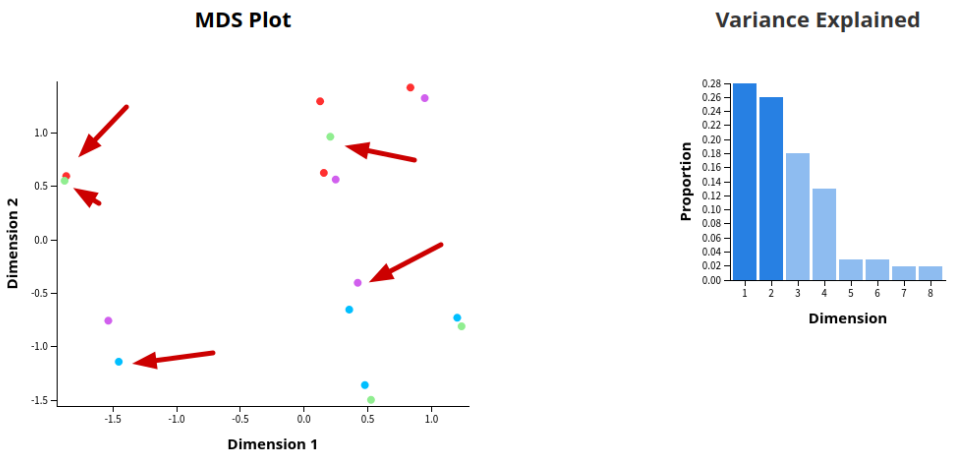

FIGURE 6 – Multi-dimensional-scaling : bleu=untreated/ rouge=dex/ vert=alb/ violet=dex+alb

L'analyse MDS a quant à elle révélée des anomalies : les dimensions 1 et 2 n'expliquent que 28% et 26% de la variance, et deux échantillons (1 Dex et 1 Untreated) se comportent comme des "outliers". Aucun gène différentiellement exprimé n'a été détecté à ce stade.

Afin de coller au plus près à la publication originale, nous avons restreint l'analyse aux conditions DEX et UNTREATED, en excluant les deux échantillons problématiques. L'analyse finale porte donc sur 3 réplicats par condition (6 échantillons).

3.3 Expression différentielle

Nous avons donc cette fois-ci séléctionner uniquement 3 lignées cellulaires traitées ou non avec DEX. Nous obtenons avec les paramèrtres suivants : Filtre : CPM $>$ 0,5 dans au moins 3 échantillons. Seuil de p-value ajustée : 0,05. Utilisation de la fonction TREAT (limma) avec un log2 Fold Change (log2FC) de 0,3. La méthode TREAT est privilégiée ici car elle permet de tester la significativité par rapport à un seuil de changement réel, évitant ainsi de sélectionner des gènes statistiquement significatifs mais biologiquement non pertinents.

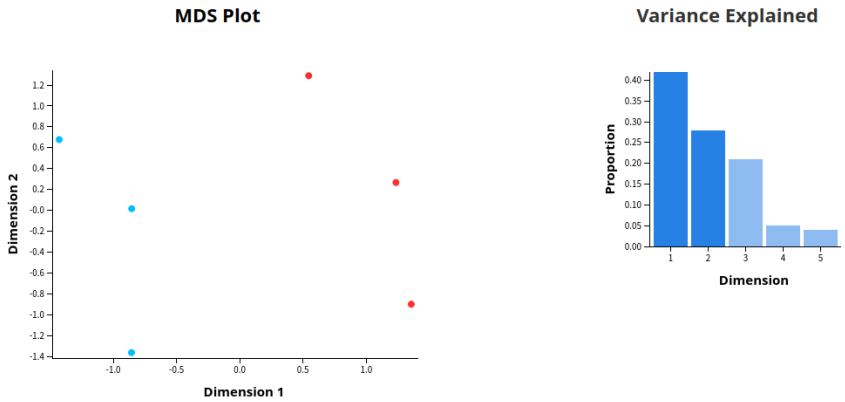

FIGURE 7 – MDS : untreated (bleu) vs DEX (rouge)

L'analyse MDS montre désormais une séparation nette sur la première dimension ($>$40% de la variance) entre les groupes traité (rouge) et non traité (bleu).

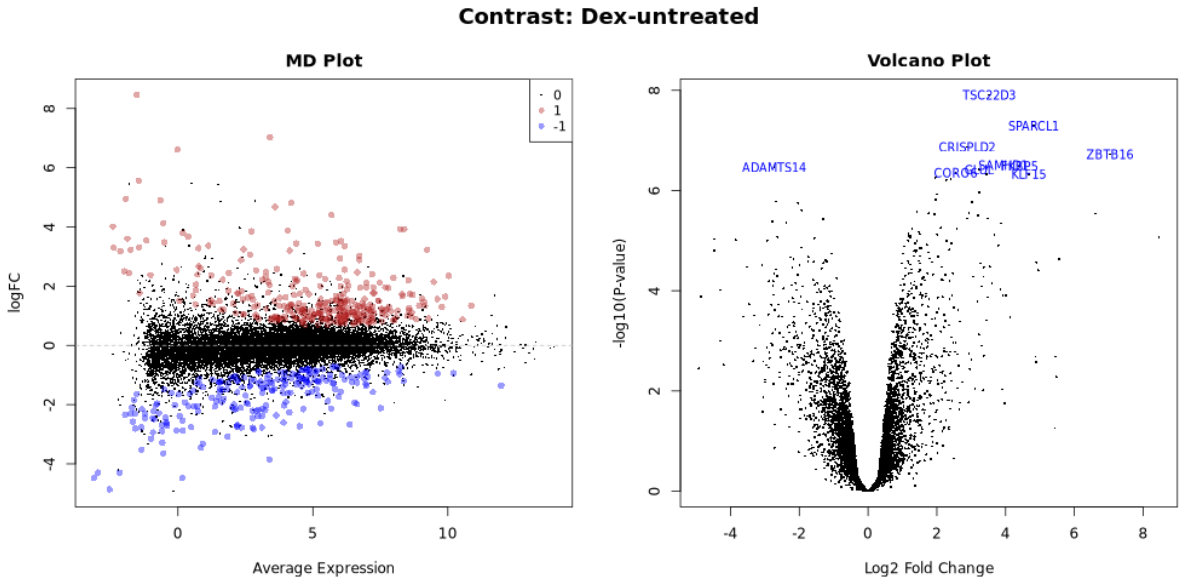

FIGURE 8 – MD & Volcano Plot

Nous identifions 318 gènes sur-exprimés (Up) et 223 gènes sous-exprimés (Down). Nous pouvons observer que CRISPLR2 est bien présent et fait partie des "top genes" (cf Figure 9), ce qui nous montre la reproducibilité des résultats de l'étude.

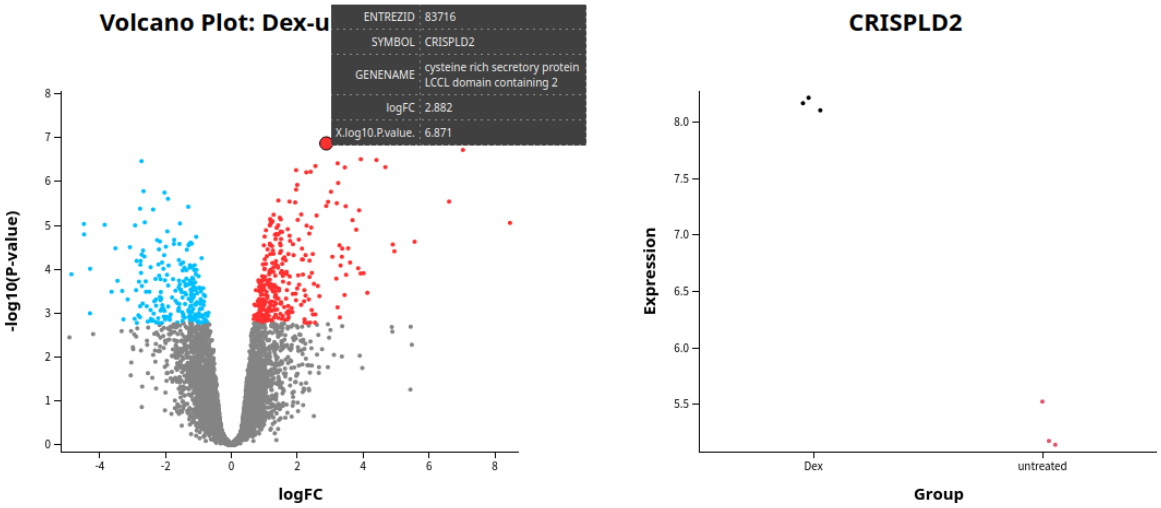

FIGURE 9 – Volcano plot après seuillage : Mise en lumière de CRISPLR2

Le volcano plot et la heat map confirment la signature génomique identifiée par Himes : on retrouve les gènes clés comme TSC22D3, KLF15 et surtout CRISPLD2. Quelques différences mineures (gènes GLUL ou ASAMS14) apparaissent, expliquées par l'utilisation d'outils et de paramètres de filtrage légèrement distincts.

Table 1. Top (Q-value <1E-10) differentially expressed genes.

Gene	locus	Mean FPKM Control	Mean FPKM Dex	Ln[Fold Chan
C7	chr5:40909598-40983042	3.76	38.41	3.35
CCDC69	chr5:150560612-150603654	6.24	47.39	2.92
DUSP1	chr5:172195092-172198203	18.26	144.96	2.99
FKBP5	chr6:35541361-35704724	3.43	53.05	3.95
GPX3	chr5:150399998-150408554	45.18	613.37	3.76
KLF15	chr3:126061477-126076236	0.86	20.46	4.58
MAOA	chrX:43515408-43606068	4.41	43.24	3.29
SAMHD1	chr20:35504569-35580246	17.27	245.78	3.83
SERPINA3	chr14:95078713-95090390	13.78	139.89	3.34
SPARCL1	chr4:88394487-88450655	1.07	27.88	4.70
C13orf15	chr13:42031541-42045013	10.00	96.35	3.27
TSC22D3	chrX:106956451-107019017	9.69	93.26	3.27
CRISPLD2	chr16:84853586-84943116	7.89	51.17	2.70
PER1	chr17:8043787-8055753	1.49	13.69	3.20
KCTD12	chr13:77454303-77460540	31.25	5.43	-2.52
ERRFI1	chr1:8071778-8086393	13.48	72.70	2.43
STEAP4	chr7:87905743-87936228	0.20	6.35	4.99

FPKM = fragments per kilobase of transcript per million mapped reads.
doi:10.1371/journal.pone.0099625.t001

	A	B	C	D	E
1	ENTREZ	SYMBOL	GENENAME	logFC	AveExpr
2	1831	TSC22D3	TSC22 domain family member 3	3,52478634471148	6,03905441328235
3	8404	SPARCL1	SPARC like 1	4,81467548851001	4,19582271614835
5	28999	KLF15	KLF transcription factor 15	4,67385677096208	3,59868367696483
6	2289	FKBP5	FKBP prolyl isomerase 5	4,40375731173227	5,6937213660962
7	25939	SAMHD1	SAM and HD domain containing deoxynucleoside triphos	3,92902144746969	8,38853953643172
8	5187	PER1	period circadian regulator 1	3,44441600637304	4,38122926887234
9	2752	GLUL	glutamate-ammonia ligase	3,22636175680181	9,23065413403114
10	83716	CRISPLD2	cysteine rich secretory protein LCCL domain containing	2,88158620618197	6,72192063281144
18	1849	DUSP1	dual specificity phosphatase 1	3,02353105033315	6,71687286836298
23	26112	CCDC69	coiled-coil domain containing 69	2,93479769592712	6,00484474164436
28	783	CACNB2	calcium voltage-gated channel auxiliary subunit beta 2	3,19879340034936	4,14034515190245
29	4128	MAOA	monoamine oxidase A	3,47034050799794	5,85446190742929
34	140711	TLDC2	TBC/LysM-associated domain containing 2	3,87834785450658	4,07216725955612
120	12	SERPINA3	serpin family A member 3	3,35499974758029	6,18310339178873
176	2878	GPX3	glutathione peroxidase 3	3,92351037794703	8,22943417865241
301	730	C7	complement C7	3,43624868409057	5,18077780583305
1063	5166	PDK4	pyruvate dehydrogenase kinase 4	3,11271891658855	4,68073514901484

Filtre standard

Critères de filtre

Opérateur	Nom de champ	Condition	Valeur
	logFC	>	2,8
ET	AveExpr	>	3,5
	- aucun(e)-	=	
	- aucun(e)-	=	

Options

Aide | Effacer | Annuler | OK

FIGURE 10 – Comparaison des "top genes" identifiés par l'étude (à gauche) et par notre analyse (à droite)

3.4 Analyse des voies métaboliques

L'analyse des voies métaboliques (cf Figure 11) a été réalisée avec goseq (catégorie Gene Ontology : Biological Process). Bien que de nombreux processus biologiques impliqués dans la réponse au traitement soient mis en évidence, les résultats diffèrent légèrement de ceux de Himes, qui s'était concentré sur un "Top 6" spécifique différent de nos top gènes.

On remarque une expression différentielle (DE) particulièrement marquée dans le "positive regulation of developmental process" et la "positive regulation of cellular process". Dans le contexte de l'asthme, cela indique que la DEX module activement la manière dont les cellules des voies respiratoires se développent et se renouvellent, ce qui est crucial pour contrer le remodelage bronchique (épaississement des parois) typique de la maladie.

Les catégories "cell communication" et "signaling" présentent des cercles de grande taille, indiquant un nombre élevé de gènes différentiellement exprimés (environ 160 à 200 gènes par catégorie).Cela démontre que la DEX interfère massivement avec les signaux d'alerte envoyés par les cellules immunitaires. Le traitement "coupe" ou modifie les voies de communication qui déclenchent normalement l'inflammation allergique.

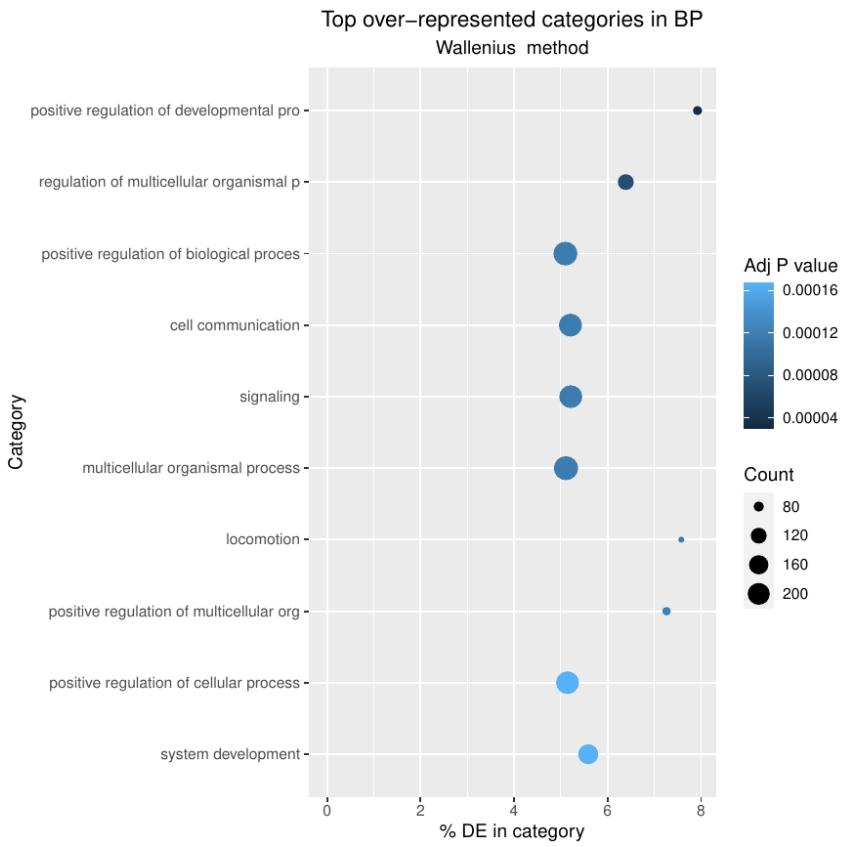

FIGURE 11 – Voies métaboliques impliquées pour les gènes différentiellement exprimés

4 Séries temporelles / RNN

4.1 Données et format

Nous utilisons trois tableaux NumPy fournis pour l'analyse séquentielle :

— `X_time` de taille $(5, 10, 4)$: $N = 5$ trajectoires, chacune observée sur $T = 10$ pas de temps, avec $D = 4$ variables (features).

— `X_test_time_true` de taille $(5, 10, 4)$: trajectoires « ground truth » (référence) au même format, utilisées pour évaluer les prédictions.

— `X_test_0` de taille $(5, 4)$: état initial ($t = 0$) des 5 trajectoires de test, i.e. un vecteur de $D = 4$ features par trajectoire.

4.2 Objectif

L'objectif est d'entraîner un modèle de type RNN à prédire l'état au temps suivant x_{t+1} à partir des états passés $x_{0:t}$, puis de générer une trajectoire complète en mode *autoregressif* :

$$\hat{x}_{t+1} = f(x_{0:t}), \qquad \text{puis } \hat{x}_{t+2} = f(x_{0:t}, \hat{x}_{t+1}), \ \ldots$$

Les prédictions $\hat{x}_t$ sont ensuite comparées à la trajectoire de référence `X_test_time_true`.

4.3 Prétraitement : standardisation

Nous standardisons les $D = 4$ features pour faciliter l'entraînement du modèle. Les paramètres de normalisation sont estimés **uniquement sur** `X_time` (toutes trajectoires et tous pas de temps)

car c'est notre dataset surlequel on va entraîner le RNN. Pour chaque feature d, on calcule une moyenne μ_d et un écart-type σ_d, puis :

$$x'^{(d)} = \frac{x^{(d)} - \mu_d}{\sigma_d}.$$

Dans nos données :

$$\mu = [5.3524,\ 5.7877,\ 6.3374,\ 5.4045], \qquad \sigma = [1.4374,\ 1.1374,\ 0.9960,\ 1.3483].$$

Contrôles. Après transformation, `X_time_std` est bien centré-réduit (moyennes ≈ 0, écarts-types $= 1$ par feature).

4.4 Construction du dataset supervisé

Le but est d'apprendre au modèle à prédire **le prochain pas de temps** à partir de ce qu'il a déjà vu. Autrement dit, si on lui donne les valeurs aux temps $0, 1, \ldots, t-1$, il doit deviner les valeurs au temps t.

Nos données `X_time_std` ont la taille $(N, T, D) = (5, 10, 4)$: 5 séries temporelles, 10 pas de temps, et 4 variables par pas de temps. Pour chaque série, on peut créer 9 « exercices » :

— entrée = valeurs de $t = 0$ pour prédire $t = 1$,
— entrée = valeurs de $t = 0, 1$ pour prédire $t = 2$,
— ...
— entrée = valeurs de $t = 0, \ldots, 8$ pour prédire $t = 9$.

Cela fait donc $5 \times 9 = 45$ exemples supervisés au total.

Padding. Les entrées n'ont pas toutes la même longueur (parfois on n'a qu'un seul pas passé, parfois on en a neuf). Pour pouvoir regrouper tous les exemples dans un même tableau, on complète les séquences les plus courtes avec une valeur spéciale (`PAD_VALUE`=999.0) jusqu'à la longueur maximale (9 pas). On obtient alors :

$$X_{\text{in}} \in \mathbb{R}^{45\times 9\times 4}, \qquad y \in \mathbb{R}^{45\times 4},$$

où y correspond à la « bonne réponse » (le prochain pas de temps). La valeur 999.0 n'apparaît pas dans les données réelles, ce qui permettra au RNN d'ignorer automatiquement ce remplissage (via un masquage).

Split train/validation. Pour évaluer correctement, on sépare les données **par série** (par trajectoire) : 4 séries servent à l'entraînement (36 exemples) et la dernière à la validation (9 exemples). Cela évite que la validation contienne des morceaux d'une trajectoire déjà vue pendant l'entraînement.

4.5 Modèle RNN (GRU) et configuration

Nous utilisons un réseau récurrent de type **GRU** pour prédire le prochain pas de temps (prédiction *one-step*). L'entrée est une séquence de taille $(9, 4)$ (9 pas au maximum après padding, 4 features), et la sortie est un vecteur de taille 4 correspondant à l'état au temps suivant.

Gestion du padding. Les séquences d'entrée ayant été paddées avec la valeur `PAD_VALUE`=999.0, nous ajoutons une couche `Masking` afin que le modèle **ignore** automatiquement les pas de temps artificiels.

Architecture. Le modèle est composé de :

— une couche `Masking` (0 paramètre),
— une couche `GRU` avec 32 unités (3 648 paramètres),
— une couche `Dense` finale de dimension 4 (132 paramètres).

Le modèle comporte au total 3 780 paramètres entraînables, ce qui reste volontairement petit au vu de la taille réduite du dataset.

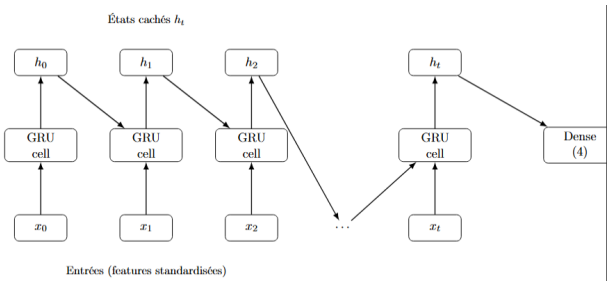

FIGURE 12 – Schéma du GRU déroulé dans le temps : chaque cellule reçoit x_t et l'état caché précédent, puis produit h_t. La tête Dense prédit le prochain état $\hat{x}_{t+1}$.

Entraînement. Nous optimisons la **MSE** (*mean squared error*) et nous suivons également la **MAE** (*mean absolute error*) comme métrique d'évaluation.

4.6 Entraînement et early stopping

Le modèle est entraîné sur `X_train` (36 exemples) et évalué sur `X_val` (9 exemples), avec une fonction de perte MSE et la métrique MAE. L'optimisation est faite sur un maximum de 300 époques (batch size = 8).

Afin d'éviter le sur-apprentissage (*overfitting*), nous utilisons un **early stopping** basé sur la perte de validation (`val_loss`), avec une patience de 20 époques. Concrètement, l'entraînement s'arrête automatiquement si `val_loss` n'améliore plus pendant 20 époques consécutives, et le modèle final correspond à l'état ayant obtenu la meilleure performance sur validation.

Observation. Au cours de l'entraînement, la perte d'entraînement diminue de façon continue, tandis que la perte de validation baisse au début puis tend à stagner.

4.7 Évaluation en mode autoregressif

Pour évaluer le modèle dans un cadre réaliste, nous utilisons une prédiction **autoregressive** : on démarre à partir de l'état initial connu (`X_test_0_std`), puis le modèle prédit le pas de temps suivant. Cette prédiction est ensuite réutilisée comme entrée pour prédire le pas suivant, et ainsi de suite jusqu'à obtenir une trajectoire complète (10 pas de temps). Autrement dit, le modèle avance dans le temps en s'appuyant sur ses propres sorties, comme ce serait le cas en pratique lorsque les valeurs futures ne sont pas disponibles.

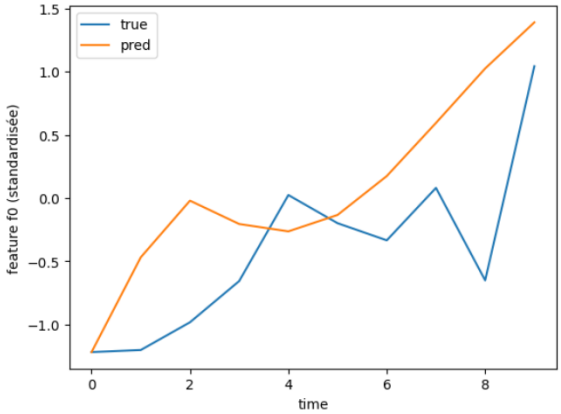

FIGURE 13 – Trajectoire vraie vs prédite (exemple).

Les trajectoires prédites ont bien la même dimension que la référence (`preds_test` de taille $(5, 10, 4)$). Sur l'ensemble des pas de temps, des variables et des 5 trajectoires de test, l'erreur globale est de **MAE** $=$ **0.348** et **MSE** $=$ **0.228** (données standardisées). L'erreur est nulle à $t = 0$ car l'état initial est imposé, puis elle reste modérée pour les pas suivants (par exemple MAE ≈ 0.49 à $t = 1$ et ≈ 0.43 à $t = 9$). Enfin, l'erreur varie selon les trajectoires, la plus difficile présentant une MAE d'environ 0.48 contre ≈ 0.29–0.36 pour les autres.

4.8 Baselines et comparaison

Afin de situer la performance du RNN, nous comparons le rollout autoregressif à deux baselines simples :

— **Persistence** (« naïf ») : on suppose que l'état reste constant, i.e. $\hat{x}_{t+1} = \hat{x}_t$.

— **Ridge (linéaire)** : un modèle de régression linéaire (Ridge) appris sur les transitions $(x_t \to x_{t+1})$ à partir de `X_time_std`, puis utilisé en rollout autoregressif.

Les résultats globaux (données standardisées, plus petit = meilleur) sont :

$$\text{Persistence : MAE} = 1.0726,\ \text{MSE} = 1.9233; \qquad \text{Ridge : MAE} = 0.4742,\ \text{MSE} = 0.3968;$$

$$\text{RNN : MAE} = 0.3485,\ \text{MSE} = 0.2281.$$

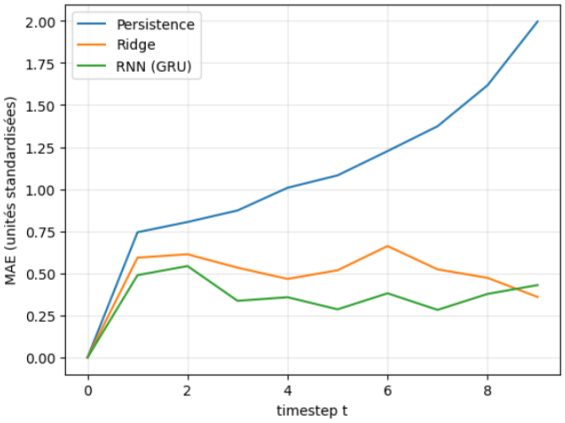

FIGURE 14 – MAE (données standardisées) en fonction du pas de temps t en rollout autoregressif : comparaison Persistence, Ridge et RNN (GRU). Plus la courbe est basse, meilleure est la prédiction.

La baseline persistence dégrade fortement avec l'horizon (MAE croissante jusqu'à ≈ 2.0 à $t = 9$), ce qui confirme que la dynamique ne peut pas être approximée par un état constant. Le

modèle linéaire Ridge améliore nettement les performances, mais reste moins précis que le RNN. Au final, le modèle GRU obtient la meilleure performance globale, suggérant qu'il capture des relations temporelles non-linéaires au-delà d'une dynamique linéaire simple.

5 Conclusion et Perspectives

Ce projet s'est articulé autour d'une double approche : une analyse bioinformatique visant à reproduire les résultats transcriptomiques de l'étude de Himes et al. (2014), et une modélisation prédictive de dynamiques temporelles par apprentissage profond.

5.1 Bilan de l'analyse transcriptomique

L'implémentation du pipeline RNA-Seq, allant du contrôle qualité à l'analyse d'expression différentielle, a permis de valider la robustesse des données biologiques malgré la nécessité d'un nettoyage rigoureux (exclusion d'échantillons aberrants identifiés par MDS).

Nos résultats confirment les conclusions majeures de l'article d'origine :

— **Validation de la signature moléculaire :** Nous avons retrouvé une séparation nette entre les cellules traitées à la dexaméthasone et les témoins. Les gènes clés identifiés par Himes, notamment *TSC22D3*, *KLF15* et surtout *CRISPLD2*, apparaissent systématiquement parmi les gènes les plus significativement régulés (FDR < 0.05).

— **Interprétation biologique :** L'analyse d'enrichissement fonctionnel (GO Term) corrobore le rôle modulateur des glucocorticoïdes sur le développement cellulaire et la communication intercellulaire, mécanismes essentiels pour contrer l'inflammation et le remodelage dans l'asthme.

— **Reproductibilité :** Bien que des différences mineures existent dans les listes exactes de gènes (dues aux versions logicielles et aux seuils de filtrage), le message biologique reste identique : *CRISPLD2* est une cible majeure des glucocorticoïdes dans le muscle lisse des voies aériennes.

5.2 Apport de la modélisation temporelle (RNN)

La seconde partie de l'étude a démontré l'intérêt de l'intelligence artificielle pour appréhender la dynamique des systèmes biologiques. L'utilisation d'un réseau de neurones récurrent de type **GRU** a surpassé les approches classiques (modèle naïf de persistance et régression Ridge) :

— Le modèle GRU a atteint une erreur minimale (**MAE $\approx$ 0.35**), prouvant sa capacité à capturer des dépendances temporelles non-linéaires complexes que les modèles linéaires échouent à modéliser.

— L'approche autorégressive permet de simuler des trajectoires d'expression génique réalistes, ouvrant la voie à des prédictions sur l'évolution de la réponse aux traitements.

5.3 Synthèse et limites

En conclusion, cette étude illustre la complémentarité entre l'analyse descriptive ("Quels gènes changent ?") et la modélisation prédictive ("Comment changent-ils dans le temps ?").

Si ces résultats offrent des prespectives intéressantes, elle ne forment pas en elle même une preuve suffisante pour déterminer l'impact d'un gène dans des mécanismes de régulation de maladies comme l'Asthme. Les modèles de simulation basés sur du Deep Learning offrent un point de vue intéressant sur l'évolution continue du traitement, sans en constituer une base suffisante pour de l'application clinique. Les outils bio-informatiques doivent donc être utilisés avec mesure et en complément à des expériences biologiques. Ils premettent cependant d'élargir les pistes de traitement de maladies fréquentes telles que l'asthme.

Références

[1] Himes, B. E., et al. (2014). *RNA-Seq Transcriptome Profiling Identifies CRISPLD2 as a Glucocorticoid Responsive Gene that Modulates Cytokine Function in Airway Smooth Muscle Cells.* PLoS ONE, 9(6), e99625.